Optimización de costos: Groq, Claude y OpenAI

Para este proyecto elegí GPT-OSS 20B mediante el plan gratuito de Groq, para desarrollar y probar la validación de consultas y la generación de borradores sin costo de IA, dentro de los límites disponibles. Groq también ofrece un plan de pago.

Cuadro comparativo

Criterio	Groq + GPT-OSS 20B	Claude Haiku 4.5	OpenAI GPT-4o mini
Modalidad evaluada	Plan gratuito	API de pago	API de pago
Costo de entrada por millón de tokens	US$ 0 dentro del plan gratuito	US$ 1	US$ 0,15
Costo de salida por millón de tokens	US$ 0 dentro del plan gratuito	US$ 5	US$ 0,60
Tarea en el proyecto	Validar datos y generar borradores	Alternativa para evaluar las mismas tareas	Alternativa para evaluar las mismas tareas
Decisión	Elegido para el prototipo	No implementado	No implementado
Limitación principal considerada	Límites de uso del plan gratuito	Costo según consumo	Costo según consumo

Tarifas estándar consultadas el 11 de octubre de 2026, sin descuentos por caché o lotes. Fuentes: documentación oficial de Claude y OpenAI.

Comparación de costo estimado

Supuesto: 500 consultas, con 1.000 tokens de entrada y 500 de salida facturables por consulta.

Alternativa	Cálculo	Costo estimado de IA
Groq Free	Uso dentro de los límites gratuitos	**US$ 0**
Claude Haiku 4.5	0,5 × US$ 1 + 0,25 × US$ 5	**US$ 1,75**
OpenAI GPT-4o mini	0,5 × US$ 0,15 + 0,25 × US$ 0,60	**US$ 0,225**

Bajo estos supuestos, el plan gratuito de Groq evita un gasto estimado de US$ 1,75 frente a Claude Haiku 4.5 o US$ 0,225 frente a GPT-4o mini, siempre que el procesamiento se mantenga dentro de sus límites.

Justificación de la elección

Se priorizó Groq por permitir construir el prototipo sin costo de inferencia. El flujo combina la validación y la redacción en una sola llamada; las búsquedas, la aprobación y el envío se realizan con Make, Airtable y Gmail, sin llamadas adicionales de IA.

La elección no demuestra una calidad superior frente a Claude u OpenAI: esa comparación requeriría probar los modelos con las mismas consultas y evaluar sus resultados.

Aunque GPT-OSS 20B es un modelo de OpenAI, en este proyecto se ejecuta mediante Groq. GPT-4o mini representa una alternativa mediante la API de OpenAI.

Las cifras son estimaciones comparativas, no consumo medido. La cantidad de tokens puede variar entre modelos. No se incluyen costos de Make, Airtable, correo ni impuestos.